SPRAWOZDANIE

Zajęcia: Matematyka Konkretna

Prowadząca: Prof. Dr.hab. inż. Vasyl Martsenyuk

Laboratorium Nr 2 Data 28.02.2026 Temat: Rozkład SVD i korelacji kolumn, i wierszy.	Mateusz Zajączek Informatyka II stopień, niestacjonarne, semestr, gr.1b

1. Polecenie:

Zadanie dotyczy obliczenia korelacji obrazu zgodnie z wariantem pod względem zarówno wierszy jak i kolumn z użyciem SVD. Przedstawić macierzy korelacji graficznie. We wniosku potraktować widoki macierzy korelacji.

Sprawozdania w postaci:

1. Sprawozdanie (plik .pdf)
2. plik .ipynb
3. pdf-eksport pliku .pynb

zachować w zdalnym repozytorium (np Github) link na który umieścić w sprawozdaniu. Sprawozdanie należy wysłać na e-uczelnie¸ w ustalonym terminie.

2. Opis programu opracowanego (kody źródłowe, rzuty ekranu)

```
from matplotlib.image import imread
import matplotlib.pyplot as plt
import numpy as np
import os

plt.rcParams['figure.figsize'] = [16,8]
A = imread('1.webp')
X = np.mean(A,-1) # convert RGB to grayscale

#img = plt.imshow(256-X)
img = plt.imshow(X)
img.set_cmap('gray')
plt.axis('off')
plt.show()
```

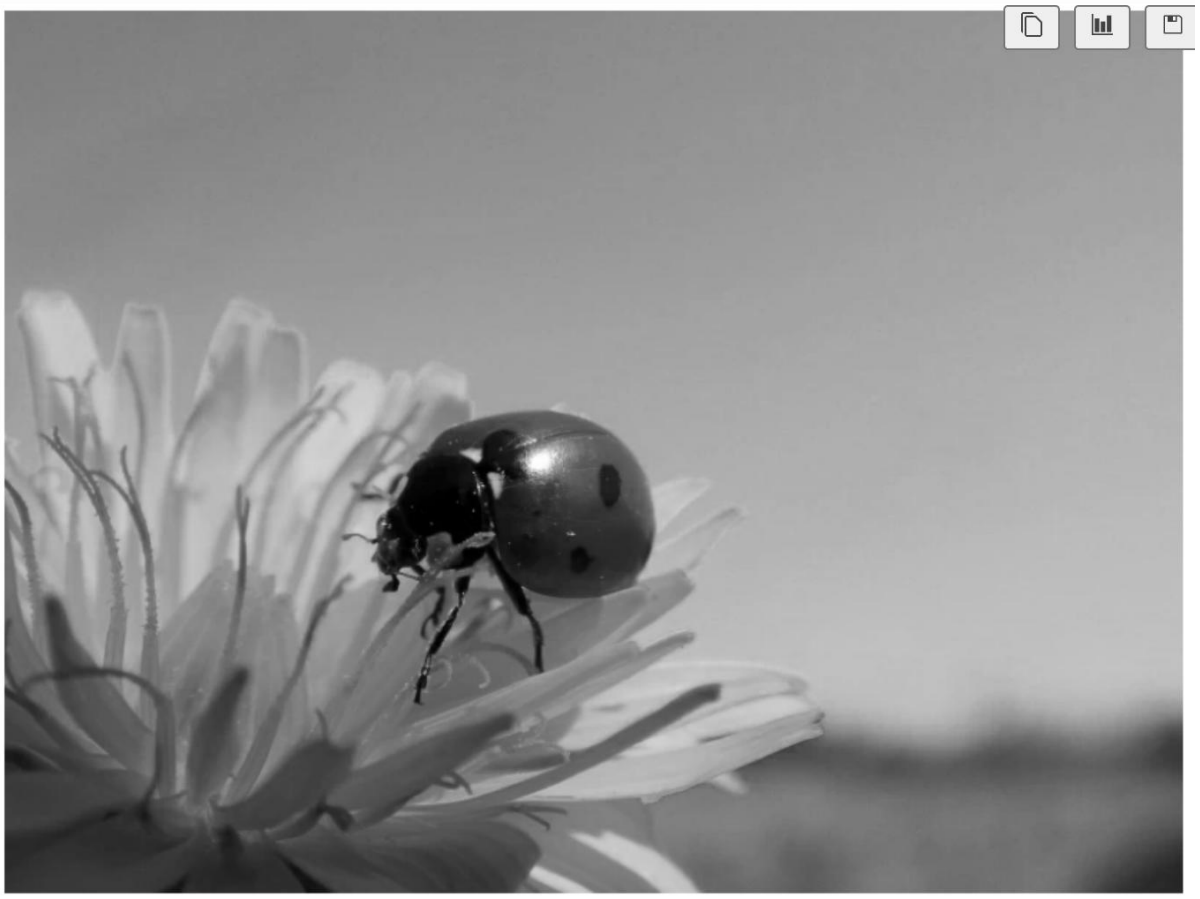

```
U, S, VT = np.linalg.svd(X,full_matrices=False)
print(S.shape)
S = np.diag(S)

j=0
for r in (5,20,100,650):
    # Construct approximate image
    Xapprox = U[:,:r]@S[0:r,:r]@VT[:r,:]
    plt.figure(j+1)
    j += 1
    #img = plt.imshow(256-Xapprox)
    img = plt.imshow(Xapprox)
    img.set_cmap('gray')
    plt.axis('off')
    plt.title('r='+str(r))
    plt.show()
```

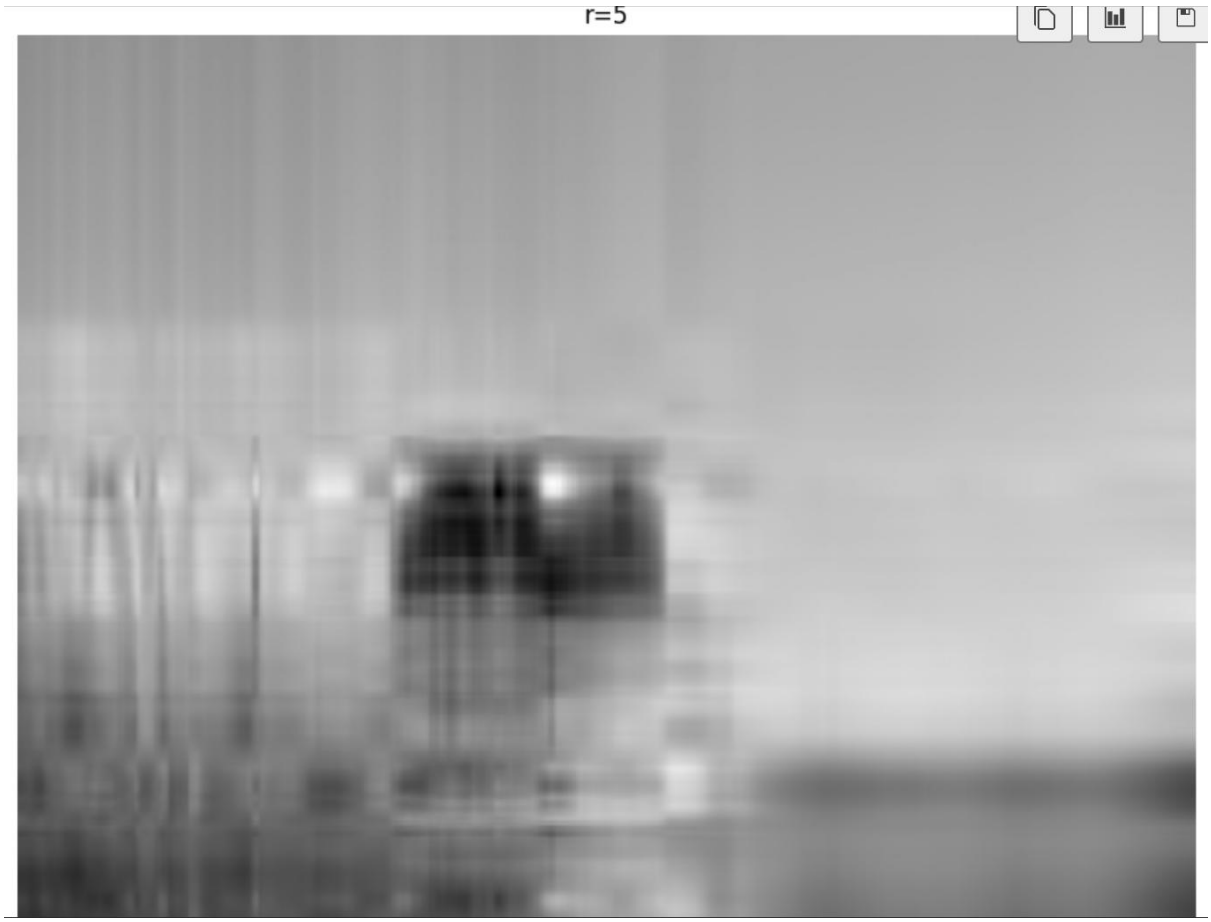

r=20

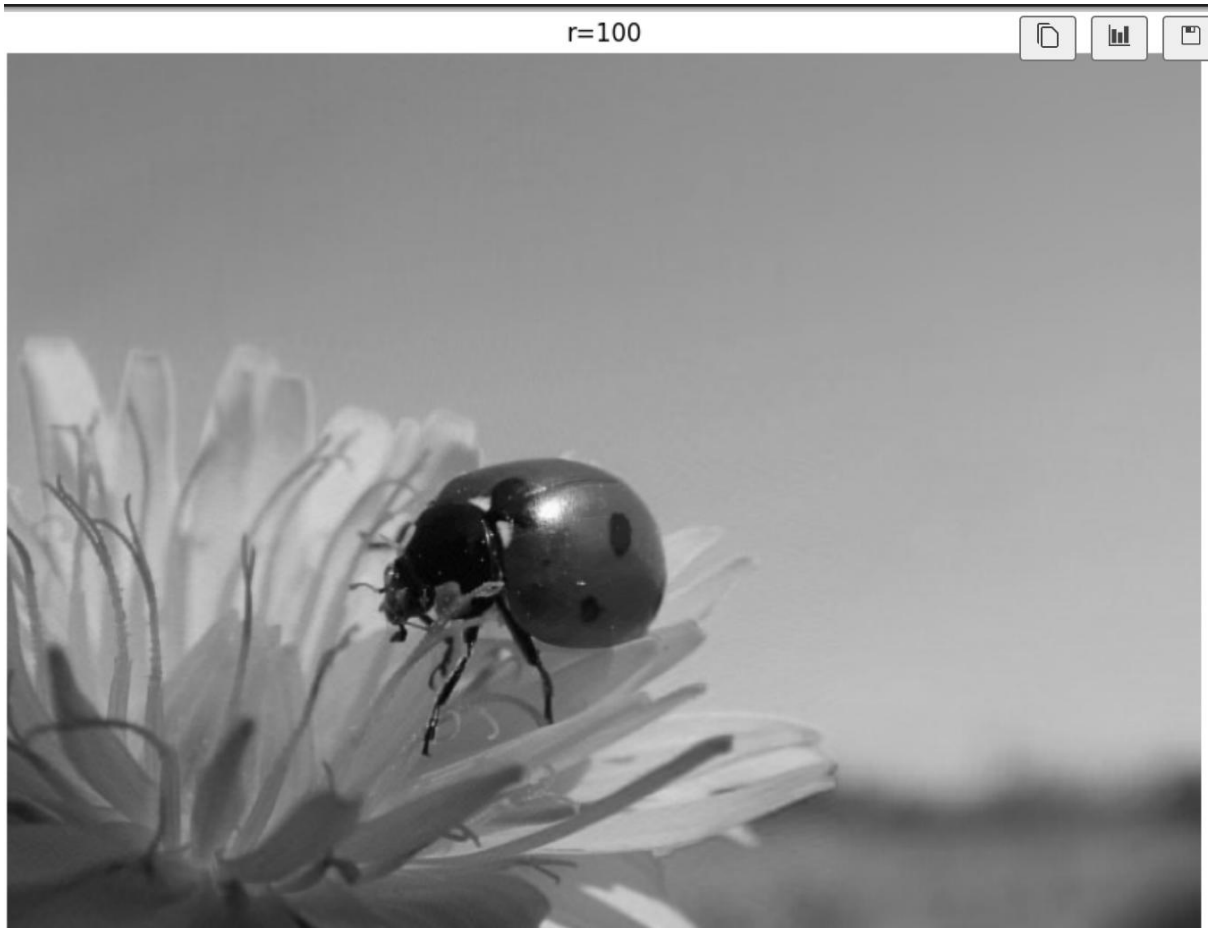
r=100

Jak interpretować otrzymane obrazy?

Dla małego r, np. (r=5)

- pozostają tylko najbardziej dominujące struktury,
- widoczne są główne obszary jasności i duże kształty,
- drobne szczegóły zanikają.

Dla (r=20)

- kontury zaczynają być znacznie lepiej rozpoznawalne,
- obraz zachowuje już ogólną strukturę sceny,
- nadal tracimy tekstury i subtelne szczegóły.

Dla (r=100)

- rekonstrukcja jest dużo wierniejsza,

- odzyskujemy znaczną część informacji wizualnej,

- drobniejsze elementy stają się zauważalne.

Dla dużego r, np. (r=650)

- obraz powinien być bardzo zbliżony do oryginału,

- różnice są niewielkie,

- do rekonstrukcji wykorzystywana jest już prawie pełna informacja.

Wniosek

Jeżeli obraz daje się dobrze przybliżyć małą liczbą składowych, to znaczy, że:

- posiada uporządkowaną strukturę,

- wiele pikseli jest pośrednio od siebie zależnych,

- informacja nie jest rozłożona równomiernie, lecz skupiona w kilku dominujących kierunkach.

```
# Correlation matrices
# correlation of rows and columns
XXT = U@S@S@U.T
print(XXT.shape)
XTX = VT.T@S@S@VT
print(XTX.shape)

img = plt.imshow(XXT)
plt.figure()
img.set_cmap('gray')
plt.axis('off')
plt.title('correlation of rows')
plt.show()

img = plt.imshow(XTX)
plt.figure()
img.set_cmap('gray')
```

```
plt.axis('off')
plt.title('correlation of columns')
plt.show()
```

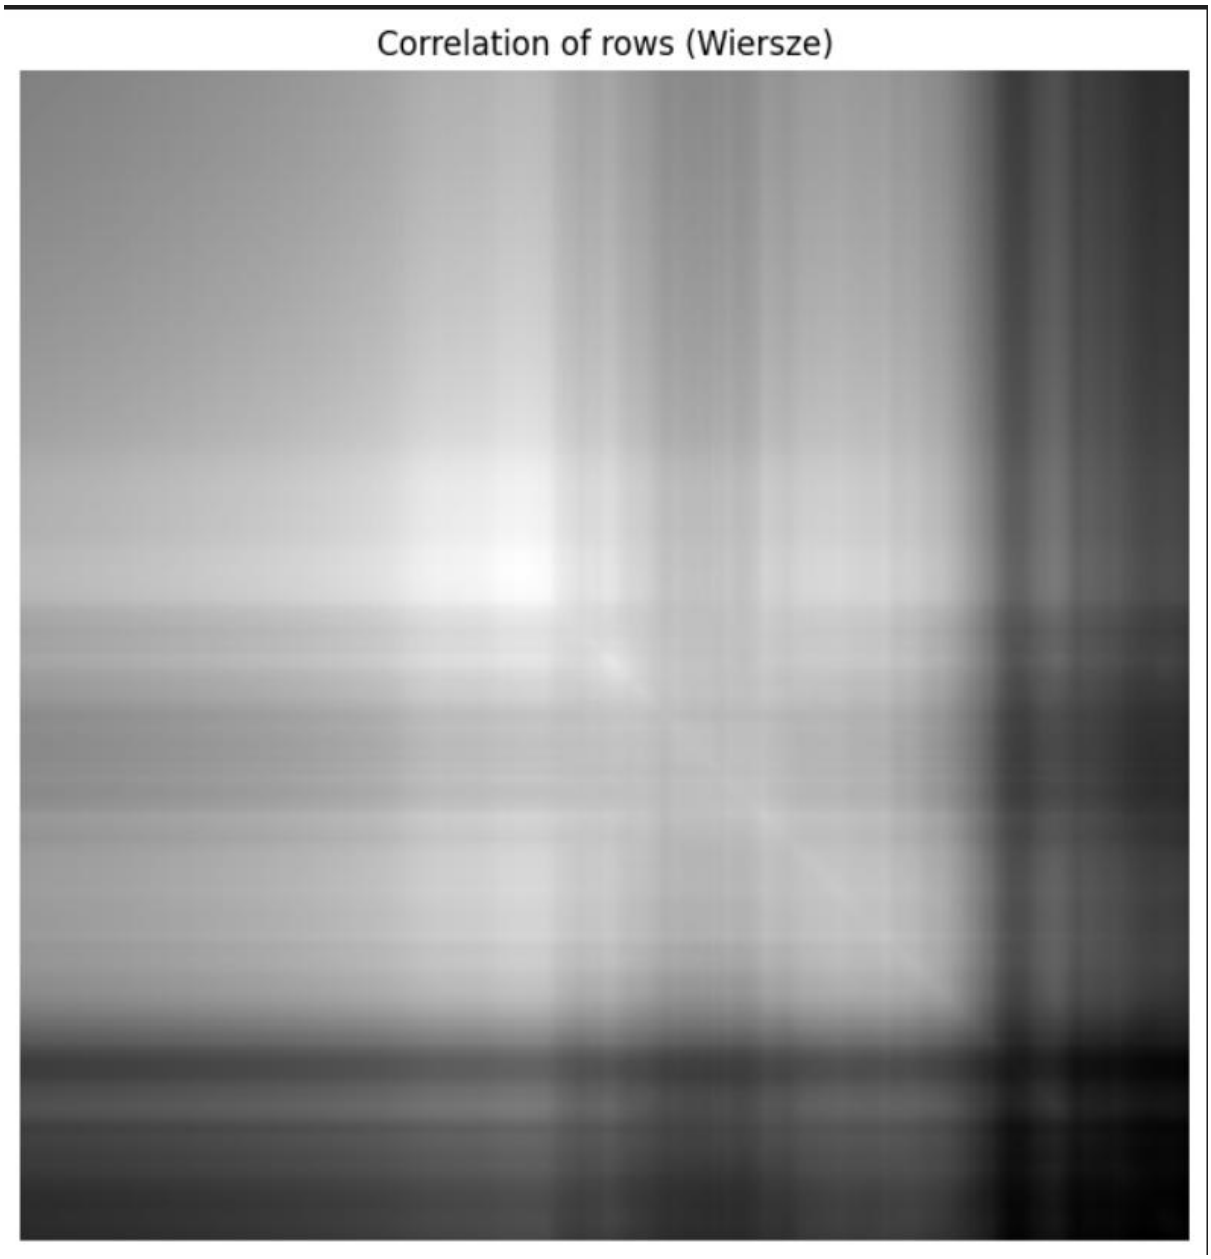

Correlation of columns (Kolumny)

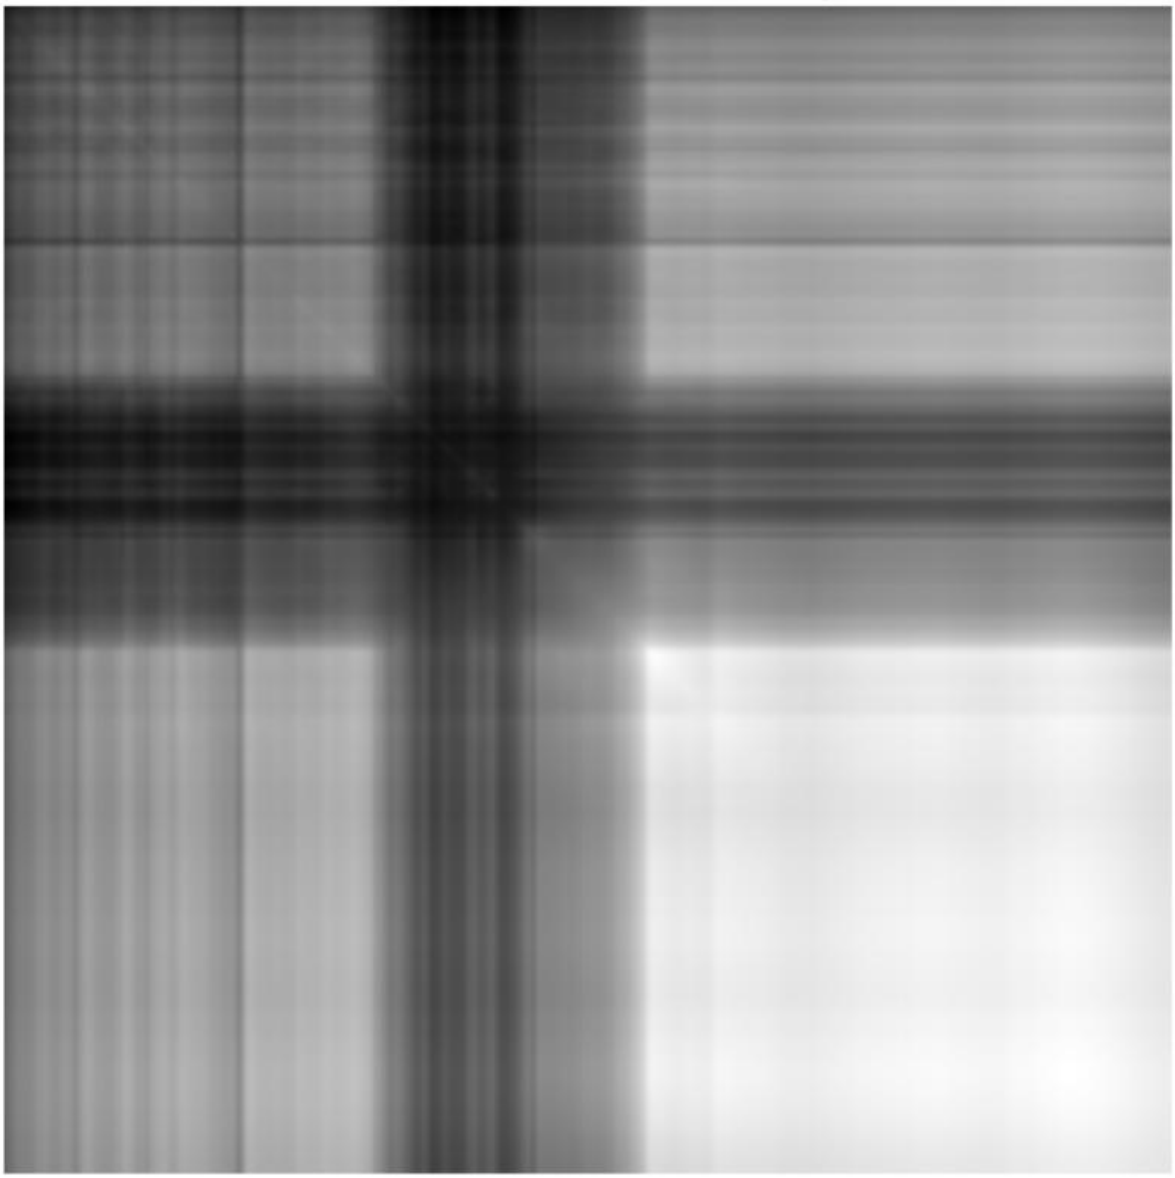

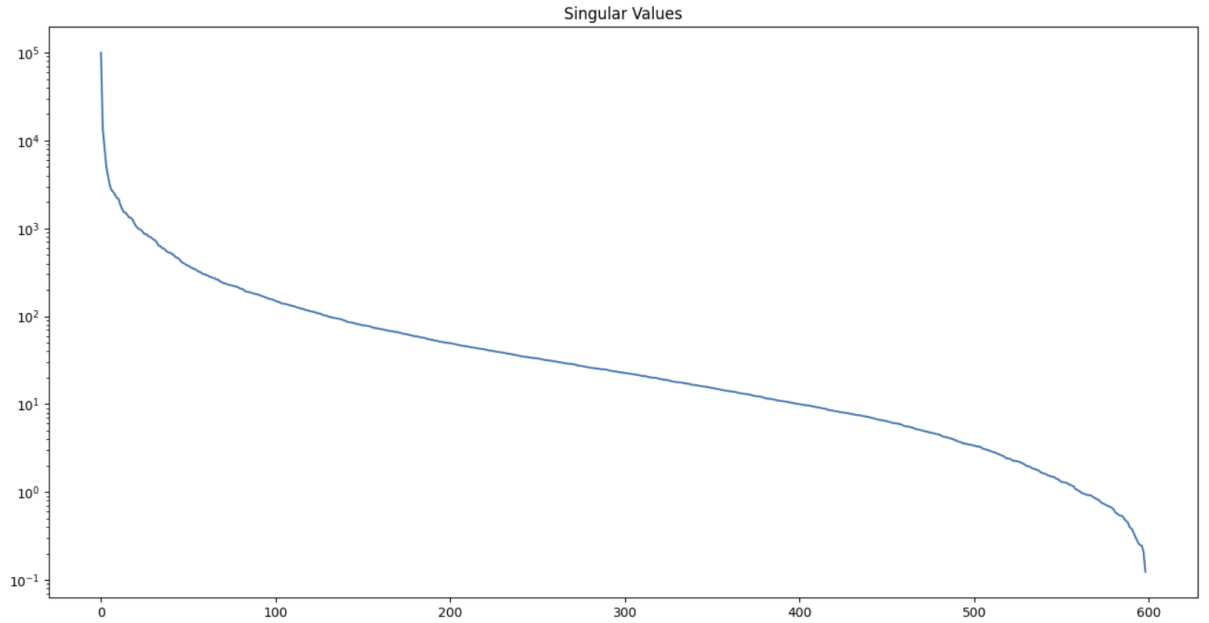

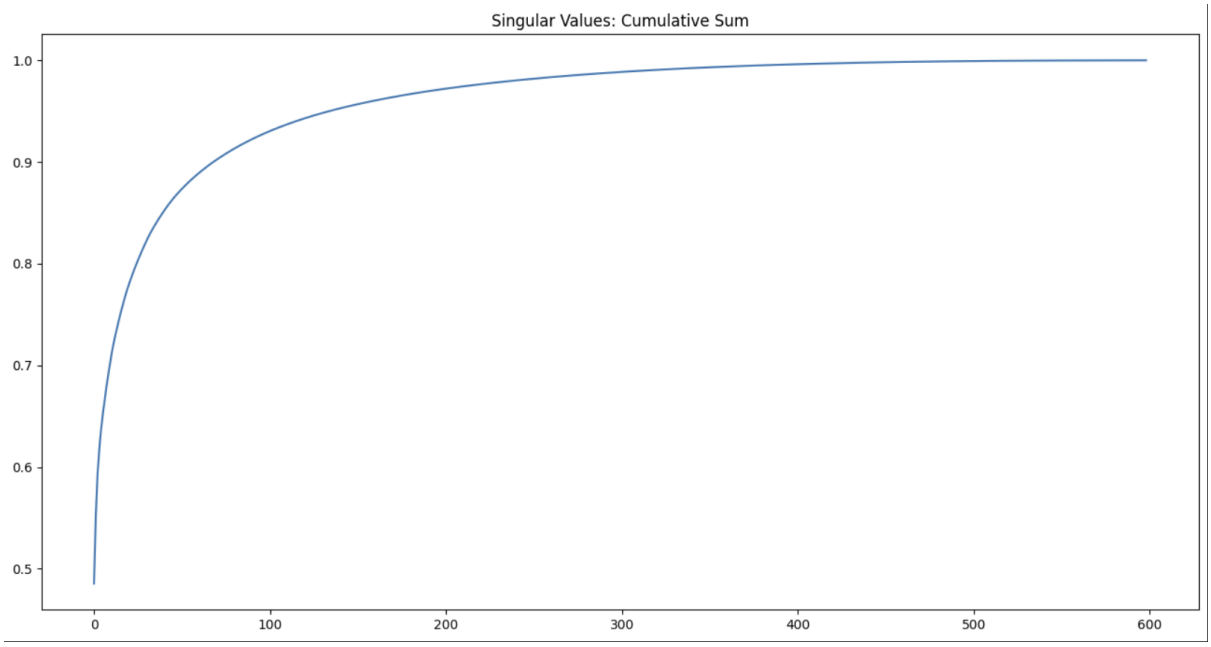

Link do githuba:

1. Które elementy obrazu znikają jako pierwsze przy małych wartościach r? Przy niskich rzędach aproksymacji (małych wartościach r, np. r=5) z obrazu jako pierwsze znikają detale, ostre krawędzie, szumy oraz tekstury (wysokie częstotliwości przestrzenne). Te elementy odpowiadają za najmniejsze wartości osobliwe w macierzy Sigma. Na ekranie pozostaje jedynie "rozmyty" zarys obrazu z uśrednionymi blokami jasności i podstawowym tłem, ponieważ największe wartości

osobliwe przechowują tylko najważniejsze i najbardziej ogólne struktury geometryczne i gradienty.

2. **Czy sąsiednie wiersze są bardziej podobne niż wiersze odległe?**
   Tak. W większości naturalnych obrazów piksele położone blisko siebie mają zbliżone wartości jasności lub koloru. W macierzy korelacji wierszy (XX^T) zjawisko to widoczne jest jako jasny pas wzdłuż głównej przekątnej, co oznacza wysoką korelację między sąsiednimi wierszami (np. i, $i+1$, $i+2$). Wraz ze wzrostem odległości od przekątnej korelacja maleje, ponieważ odpowiada to porównywaniu fragmentów obrazu coraz bardziej oddalonych przestrzennie.

3. **Czy w obrazie korelacji kolumn można zauważyć symetrię?**
   Tak. Macierze korelacji, zarówno XX^T, jak i X^TX, są z definicji symetryczne względem głównej przekątnej.

4. **Ile składowych potrzeba, aby obraz był dobrze rozpoznawalny?**
   Liczba wymaganych składowych zależy od charakterystyki analizowanego obrazu, jednak w praktyce często wystarcza wykorzystanie około 10–20% pełnego rzędu macierzy. Przykładowo, dla obrazu o rozdzielczości 650×650, wartości $r = 50$ lub $r = 100$ zazwyczaj pozwalają na uzyskanie rekonstrukcji, która jest łatwo rozpoznawalna dla ludzkiego oka i zachowuje istotne szczegóły. Dokładniejszą ocenę można uzyskać na podstawie wykresu skumulowanej sumy wartości osobliwych („Singular Values: Cumulative Sum”). Punkt, w którym krzywa zaczyna się wyraźnie wypłaszczać (tzw. „łokieć”), odpowiada zwykle poziomowi około 80–90% skumulowanej wariancji i stanowi dobrą granicę dla wyboru r. (wariancji) wyznacza z reguły dobrą granicę rozpoznawalności.

5. **Czy analizowany obraz wydaje się „prosty” czy „złożony” z punktu widzenia SVD?**
   Ocena złożoności obrazu zależy od przebiegu wartości osobliwych. W przypadku obrazów prostych (np. zawierających jednorodne tła lub proste kształty geometryczne) wartości osobliwe maleją bardzo szybko, co oznacza, że niewielka liczba składowych (np. $r \approx 10$) wystarcza do uchwycenia większości informacji (nawet powyżej 95% wariancji). Natomiast dla obrazów złożonych (np. zawierających bogate tekstury, takie jak liście drzew czy szczegółowe struktury twarzy) wartości osobliwe maleją znacznie wolniej. Wykres w skali logarytmicznej ma wtedy łagodniejszy spadek, co wskazuje, że istotna część informacji rozłożona jest również w mniejszych wartościach osobliwych. W takich przypadkach konieczne jest użycie większej liczby składowych r, aby uzyskać dobrą jakość rekonstrukcji.

3. Wnioski

I. SVD jako skuteczne narzędzie do kompresji i aproksymacji

Rozkład SVD pozwala na wydajną redukcję danych obrazu poprzez zachowanie jedynie największych wartości osobliwych, które niosą kluczowe informacje o geometrii i strukturze. Zjawisko to potwierdza fakt, że do satysfakcjonującej i rozpoznawalnej dla oka rekonstrukcji obrazu wystarczy zazwyczaj jedynie 10–20% wszystkich składowych, podczas gdy odrzucenie mniejszych wartości osobliwych eliminuje głównie szumy i drobne detale.

II. Wyraźna korelacja przestrzenna naturalnych obrazów

Wygenerowane, symetryczne macierze korelacji wierszy (XX^T) oraz kolumn (X^TX) wizualnie udowadniają zjawisko lokalnego podobieństwa pikseli w typowych fotografiach. Jasne pasy biegnące wzdłuż głównych przekątnych tych macierzy oznaczają wysoką korelację, co potwierdza, że sąsiednie fragmenty obrazu są do siebie bardzo podobne, a ich wzajemna zależność maleje wraz ze wzrostem odległości.

III. Złożoność obrazu a rozkład wartości osobliwych

Analiza wykresu skumulowanej sumy wartości osobliwych pozwala w obiektywny sposób ocenić matematyczną złożoność sceny. Charakterystyczny punkt załamania krzywej (tzw. "łokieć"), zazwyczaj pojawiający się w okolicach 80-90% skumulowanej wariancji, stanowi idealne kryterium do wyboru optymalnego rzędu aproksymacji r, balansując między jakością rekonstrukcji a stopniem kompresji.